HDFS

Tomás Fernández Pena

Máster en Tecnologías de Análisis de Datos Masivos: Big Data

Universidade de Santiago de Compostela

Tecnologías de Computación para Datos Masivos

citius.usc.es

Índice

Índice

Filesystems en Hadoop

Hadoop tiene una noción abstracta de los filesystems

- HDFS es un caso particular de filesystem

no es necesario usar HDFS con Hadoop

Algunos filesystems soportados:

FS	URI	Descripción
`Local`	*file*	Disco local
`HDFS`	*hdfs*	Sistema HDFS
`HFTP`	*hftp*	RO acceso a HDFS sobre HTTP
`HSFTP`	*hsftp*	RO acceso a HDFS sobre HTTPS
`WebHDFS`	*webhdfs*	RW acceso a HDFS sobre HTTP
`S3` (nativo)	*s3n*	Acceso a S3 nativo
`S3` (block)	*s3*	Acceso a S3 en bloques

Ejemplo:

- `hadoop fs -ls file:///home/pepe`

Para usar con HDFS se recomienda el comando `hdfs dfs`:

- `hdfs dfs -help`

Interactuar con HDFS

Tres modos principales: modos de usar HDFS

1. Usando línea de comandos: comando `hdfs dfs`
   - Permite cargar, descargar y acceder a los ficheros desde línea de comandos
   - Vale para todos los filesystems soportados
2. Usando el interfaz web
3. Programáticamente: API Java
4. Mediante otras interfaces: WebHDFS, HFTP, HDFS NFS Gateway

Índice

Interfaz en línea de comandos (I)

Algunos comandos de manejo de ficheros

Comando	Significado
`hdfs dfs -ls <path>`	Lista ficheros
`hdfs dfs -ls -R <path>`	Lista recursivamente
`hdfs dfs -cp <src> <dst>`	Copia ficheros HDFS a HDFS
`hdfs dfs -mv <src> <dst>`	Mueve ficheros HDFS a HDFS
`hdfs dfs -rm <path>`	Borra ficheros en HDFS
`hdfs dfs -rm -r <path>`	Borra recursivamente
`hdfs dfs -cat <path>`	Muestra fichero en HDFS
`hdfs dfs -tail <path>`	Muestra el final del fichero
`hdfs dfs -stat <path>`	Muestra estadísticas del fichero
`hdfs dfs -mkdir <path>`	Crea directorio en HDFS
`hdfs dfs -chmod ...`	Cambia permisos de fichero
`hdfs dfs -chown ...`	Cambia propietario/grupo de fichero
`hdfs dfs -du <path>`	Espacio en bytes ocupado por ficheros
`hdfs dfs -du -s <path>`	Espacio ocupado acumulado
`hdfs dfs -count <paths>`	Cuenta nº dirs/ficheros/bytes

Interfaz en línea de comandos (II)

Movimiento de ficheros del sistema local al HDFS:

Comando	Significado
`hdfs dfs -put <local> <dst>`	Copia de local a HDFS
`hdfs dfs -copyFromLocal ...`	Igual que -put
`hdfs dfs -moveFromLocal ...`	Mueve de local a HDFS
`hdfs dfs -get <src> <loc>`	Copia de HDFS a local
`hdfs dfs -copyToLocal ...`	Copia de HDFS a local
`hdfs dfs -getmerge ...`	Copia y concatena de HDFS a local
`hdfs dfs -text <path>`	Muestra el fichero en texto

Interfaz en línea de comandos (III)

Otros comandos:

Comando	Significado
`hdfs dfs -setrep <path>`	Cambia el nivel de replicación
`hdfs dfs -test -[defsz] <path>`	Tests sobre el fichero
`hdfs dfs -touchz <path>`	Crea fichero vacío
`hdfs dfs -expunge`	Vacía la papelera
`hdfs dfs -usage [cmd]`	Ayuda uso de comandos

Más información: http://hadoop.apache.org/docs/stable/hadoop-project-dist/hadoop-common/FileSystemShell.html

Índice

Interfaz Java

API que permite interactuar con los filesystems soportados por Hadoop

- Utiliza la clase abstracta `org.apache.hadoop.fs.FileSystem`

Otras clases de interés en `org.apache.hadoop.fs` y `org.apache.hadoop.io`

- `Path`: representa a un fichero en un FileSystem
- `FileStatus`: información del fichero
- `FSDataInputStream`: stream de entrada de datos para un fichero, con acceso aleatorio
- `FSDataOutputStream`: stream de salida de datos para un fichero
- `IOUtils`: Funcionalidades para I/O

Ejemplo: lectura de un fichero en HDFS

```
public class FileSystemCat {
   public static void main(String[] args) throws Exception {
        String uri = args[0];
        // Configuracion por defecto
        Configuration conf = new Configuration();
        // Objeto para acceder al filesystem HDFS
        FileSystem fs = FileSystem.get(URI.create(uri), conf);
        // InputStream
        FSDataInputStream in = null;
        try {
            // Abre el FSDataInputStream con el PATH indicado
            in = fs.open(new Path(uri));
            // Copia con un buffer de 4096 bytes
            // No cierra los buffers al terminar (false)
            IOUtils.copyBytes(in, System.out, 4096, false);
        } finally {
            IOUtils.closeStream(in);
        }}}
```

Ejecución del código anterior

Compilación: comando `javac` (suponiendo package test)

```
$ javac -cp $(hadoop classpath) test/FileSystemCat.java
```

Definir correctamente la variable HADOOP_CLASSPATH y usar el comando `hdfs` para lanzar el fichero `class`

```
$ export HADOOP_CLASSPATH="."
$ hdfs test.FileSystemCat fichero_en_HDFS
```

También es posible obtener el fichero jar y ejecutarlo con `hadoop jar` (no es una aplicación YARN)

FSDataInputStream

Interfaces implementadas por `FSDataInputStream`:

1. `Seekable`: permite movernos a una posición en el fichero (método `seek`)
2. `PositionedReadable`: permite copiar a un buffer partes de un fichero

Escritura de ficheros

Dos métodos de `FileSystem` para abrir los ficheros para escritura:

1. `create`: crea un fichero para escritura (crea los directorios padre, si es preciso)
2. `append`: abre un fichero para añadir datos

Ambos métodos devuelven un `FSDataOutputStream`

- `FSDataOutputStream` no permite seek (solo escritura al final del fichero)
- El método `hflush()` garantiza coherencia, los datos son visibles para nuevos lectores
- El método `hsync()` garantiza que los datos se mandan a disco (pero pueden estar en la caché del disco)

Otras operaciones con ficheros y directorios

Crear un directorio:

- Método `mkdirs` de `FileSystem`

Información sobre ficheros y directorios:

- Métodos `getFileStatus` y `listStatus` de `FileSystem`
- Clase `FileStatus`

Patrones de nombres de ficheros (*globbing*)

- Método `globStatus` de `FileSystem`
- Interfaz `PathFilter`, para filtrar con expresiones regulares

Borrar ficheros o directorios, de forma recursiva o no:

- Método `delete` de `FileSystem`

Otras herramientas para mover datos

Es posible mover datos a/desde HDFS usando otras herramientas

- `distcp` Transferir datos en paralelo entre dos filesystems Hadoop
  - Ejemplo

```
hadoop distcp hdfs://nnode1/foo hdfs://nnode2/bar
```

  - Aplicación MapReduce map-only
  - Puede usar otros filesystems (HFTP, WebHDFS, etc.)
  - Interesante para mover cantidades masivas de datos
  - Más opciones: `hadoop distcp`
- Apache Flume servicio para recoger, agregar y mover grandes cantidades de datos de log a HDFS
- Apache Sqoop transferencia masivas de datos entre bases de datos estructuradas y HDFS

Índice

Herramientas para la gestión del HDFS

Hadoop proporciona un conjunto de herramientas para chequear y optimizar el HDFS

- `hdfs dfsadmin`: optiene información del estado del HDFS
- `hdfs fsck`: chequeo del filesystem
- `hdfs balancer`: herramienta de rebalanceo de bloques entre datanodes

`hdfs dfsadmin`

Algunas opciones (usar `hdfs dfsadmin` **comando**)

Comando	**Significado**
`-help`	Ayuda
`-report`	Muestra estadísticas del filesystem

`-setQuota`
 	
`-clrQuota`
	Fija una cuota en el número de nombres en un directorio (nº de ficheros/directorios)
	Borra la cuota de nombres

`-setSpaceQuota` `-clrSpaceQuota`	Fija una cuota en el espacio ocupado en un directorio Borra la cuota de espacio
`-refreshNodes`	Actualiza los nodos que se pueden conectar
`-safemode` `-saveNameSpace`	fija o chequea el *safe mode* en *safe mode*, salva el filesystem en memoria a un nuevo fichero `fsimage` y resetea el fichero `edits`

hdfs fsck

Chequea la salud de los ficheros en HDFS

- Chequea los bloques:
  - *Over-replicated*: con replicas de más
  - *Under-replicated*: con replicas de menos
  - *Misreplicated*: replicas mal colocadas
  - Corruptos
  - *Missing replicas*: sin réplicas
- Ejemplos:
  - Chequea recursivamente todo el HDFS

    ```
    hdfs fsck /
    ```
  - Informa del número de bloques de un fichero y su localización

```
hdfs fsck /user/pepe/foo -files -blocks -racks
```


Índice

Otras interfaces a HDFS

Otros modos de acceder a HDFS

- WebHDFS: proporciona una API REST para acceder a HDFS mediante HTTP
  - Necesita acceso a los nodos del cluster (los datos se transmiten directamente desde los nodos)
  - Activada mediante la propiedad `dfs.webhdfs.enabled` del fichero `hdfs-site.xml` del Namenode (por defecto, `true`)
- HttpFS: servidor que proporciona un gateway REST HTTP que soporta las operaciones de HDFS (lectura/escritura)
  - El servidor de HttpFS actúa como gateway: permite acceder a los datos en HDFS detrás de un firewall
- HDFS NFS Gateway: soporta NFSv3 y permite que HDFS sea montado como parte del sistema de ficheros local del cliente
  - Permite usar HDFS como un sistema de ficheros UNIX local
  - Permite copiar ficheros de HDFS al sistema de ficheros local y viceversa

Índice

Namenode principal

Estructura de directorios

```
${dfs.namenode.name.dir}/
├── current
│   ├── VERSION
│   ├── edits_0000000000000000001-0000000000000000019
│   ├── edits_inprogress_0000000000000000020
│   ├── fsimage_0000000000000000000
│   ├── fsimage_0000000000000000000.md5
│   ├── fsimage_0000000000000000019
│   ├── fsimage_0000000000000000019.md5
│   └── seen_txid
└── in_use.lock
```


Ficheros en el namenode

Ficheros en `dfs.namenode.name.dir`

- `VERSION` información sobre la versión de HDFS
- Ficheros `edits_startID-endID`: logs de transacciones ya finalizadas
- Fichero `edits_inprogress_startID`: logs de transacciones actuales
- Ficheros `fsimage`: información de los metadatos del filesystem
  - Contiene información de directorios y ficheros, incluyendo los bloques (inodos) que los forman
  - La localización de los bloques en los Datanodes se guarda en memoria

Inicio del Namenode

Cuando se inicia el Namenode:

1. Carga el último `fsimage` en memoria y aplica las modificaciones indicadas en `edits`
2. Con esta imagen reconstruida, crea un nuevo `fsimage` y un `edits` vacío
3. Espera a que los Datanodes le envíen información de los bloques que tienen
   - Esta información se guarda en memoria

Modo seguro

Durante la inicialización, el sistema está en modo seguro (*safe mode*)

- Solo permite acceso de lectura
- El modo seguro termina 30 segundos después de que el 99.9 % de los bloques alcancen un nivel mínimo de replicación
- Propiedades ajustables:

Propiedad	**Por defecto**
`dfs.namenode.replication.min`	1
`dfs.namenode.safemode.threshold-pct`	0.999
`dfs.namenode.safemode.extension`	30 s

Checkpoint node (aka Namenode secundario)

En un sistema ocupado, el fichero del `edits` puede crecer demasiado

- El Checkpoint Node se ocupa de mezclar `edits` y `fsimage` para inicializarlo
  - Proceso costoso en recursos
  - El CPN tiene requisitos de memoria similares a los del NN
- Checkpoint realizado cada hora (`dfs.namenode.checkpoint.period`) o cada 1 M transacciones (`dfs.namenode.checkpoint.txns`)
- Se puede cambiar por un Backup Node
  - Replica completa de la memoria del NN (necesita la misma cantidad de memoria)
  - Realiza los checkpoints

En caso de fallo total del Namenode, se puede recuperar el último checkpoint

- Iniciar el demonio del Namenode usando `hdfs namenode -importCheckpoint`

Checkpoint node

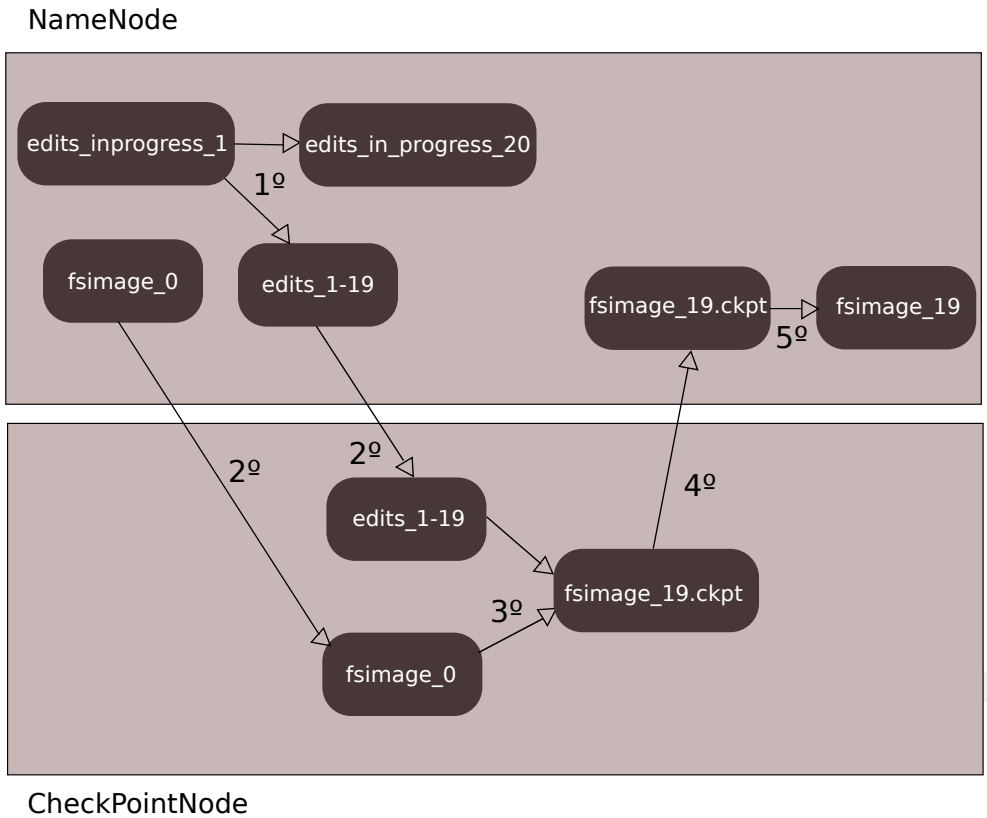

1. NN rota el fichero de edits actual. En seen_txid guarda el ID de la última transacción
2. CPN obtiene el último fsimage y edits del NN
3. CPN mezcla los ficheros
4. CPN transfiere la mezcla al NN
5. NN renombra fsimage

Localización de las replicas

Política por defecto:

- 1ª réplica: en el nodo del cliente o en un nodo al azar
- 2ª réplica: en un **rack** diferente de la primera (elegido al azar)
- 3ª réplica: en el mismo rack que la 2ª, pero en otro nodo
- Otras réplicas: al azar (se intenta evitar colocar demasiadas réplicas en el mismo rack)

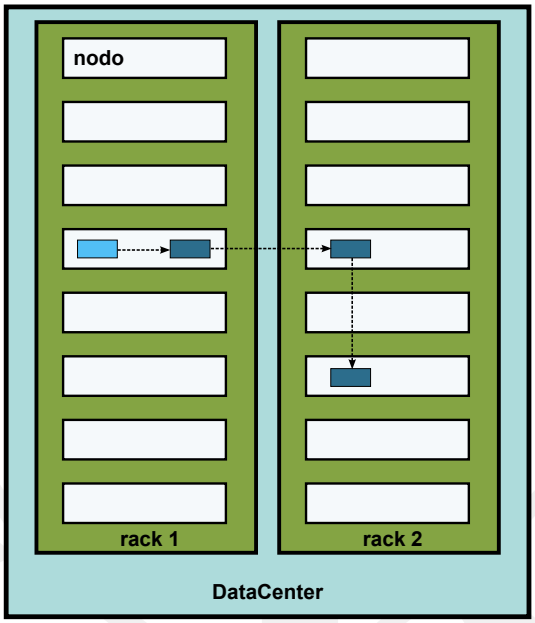

- Más información hadoop.apache.org/docs/stable/hadoop-project-dist/hadoop-hdfs/HdfsDesign.html#Data_Replication

Problemas con el Namenode

El Namenode es un *single point of failure* (SPOF)

- Si falla es imposible acceder a los datos
- Posibilidad de recuperación a partir de los checkpoints
- Conveniente guardar varias réplicas de los datos del namenode (RAID, indicar en `dfs.namenode.name.dir` directorios en diferentes máquinas, etc)

Mejoras en la versión 2.0

- HDFS High-Availability
- HDFS Federation

HDFS High-Availability

Un par de Namenodes en configuración activo-standby

- si falla el Namenode activo, el otro ocupa su lugar

Consideraciones

- Los Namenodes deben usar un almacenamiento compartido de alta disponibilidad
- Los Datanodes deben enviar informes de bloques a los dos Namenodes (el block mapping va en memoria, no en disco)
- Los Clientes deben manejar el fallo del Namenode de forma transparente

Más información: hadoop.apache.org/docs/stable/hadoop-project-dist/hadoop-hdfs/HDFSHighAvailabilityWithNFS.html, hadoop.apache.org/docs/stable/hadoop-project-dist/hadoop-hdfs/HDFSHighAvailabilityWithQJM.html

HDFS Federation

El Namenode mantiene, en memoria, referencias a cada fichero y bloque en el filesystem

- problemas de escalabilidad

HDF Federation, introducida en la versión 2.0

- Permite usar varios Namenodes
- Cada uno gestiona una porción del espacio de nombres del filesystem
- Los Namenodes no se coordinan entre sí
- Cada Datanodes se registra con todos los Namenodes

Más información: hadoop.apache.org/docs/stable/hadoop-project-dist/hadoop-hdfs/Federation.html

Hadoop v3

Novedades en HDFS v3

- Uso de **códigos de borrado** (*erasure coding*) para reducir el overhead de la replicación
  - Reduce el overhead a no más del 50 %
  - Ejemplo: ficheros de 6 bloques:
    - replicación x3: 18 bloques
    - EC: 9 bloques (6 datos + 3 paridad)
  - Implica un mayor coste de procesamiento
- Soporte de múltiples NameNodes en stand-by
- Soporte de balanceo de datos intra-nodo